Lexique du projet

Isolation Forest :

Un algorithme qui repère les anomalies en essayant de les isoler. Il découpe les données au hasard, par des coupures successives, et compte combien de coupures il faut pour qu'une transaction se retrouve seule. Une transaction ordinaire, entourée de milliers de semblables, demande beaucoup de coupures. Une transaction rare et atypique, comme une fraude, est isolée en quelques coupures seulement. En répétant l'opération sur 100 arbres et en faisant la moyenne, chaque transaction reçoit un score « d'anormalité ». Aucune étiquette de fraude n'est nécessaire pour l'entraînement.

Contamination :

Le paramètre qui règle la part de transactions que l'on accepte de déclarer suspectes. Avec une contamination de 0,01, le modèle signale les 1 % de transactions les plus anormales. Trop bas, il laisse passer des fraudes. Trop haut, il bloque des clients honnêtes. Dans notre projet, nous l'avons fait varier de 0,001 à 0,01.

Précision :

Parmi toutes les alertes déclenchées, la part qui correspond à de vraies fraudes. Isolation Forest a une précision de 0,31 : environ 1 alerte sur 3 était une vraie fraude, les 2 autres étaient des fausses alertes. Une précision élevée évite d'embêter les clients pour rien.

Rappel :

Parmi toutes les vraies fraudes, la part que le modèle a réussi à détecter. Avec un rappel de 0,34, Isolation Forest a trouvé 33 fraudes sur 98. Un rappel élevé évite de laisser passer des fraudes.

Le compromis :

Précision et rappel tirent dans des sens opposés : en augmentant la contamination, on attrape plus de fraudes (rappel en hausse) mais on déclenche plus de fausses alertes (précision en baisse).

Apprentissage non supervisé :

Le modèle apprend seul ce qui est « normal », sans qu'on lui montre d'exemples de fraude. Les étiquettes ne servent qu'à mesurer ses résultats, après coup.